3.1 Transformationen in Spark: Narrow vs. Wide

Narrow Transformations

- Jede Zeile wird **unabhängig** verarbeitet
- **Kein** Datenaustausch über das Netzwerk

Beispiele: select(), filter(), withColumn()

Wide Transformations

- Ergebnis hängt von Zeilen aus **mehreren Partitionen** ab
- Erfordert **Datenaustausch** über das Netzwerk (Shuffle)

Beispiele: groupBy(), join(), orderBy()



Abb. 3.1: Narrow, jede Partition bleibt auf ihrem Knoten

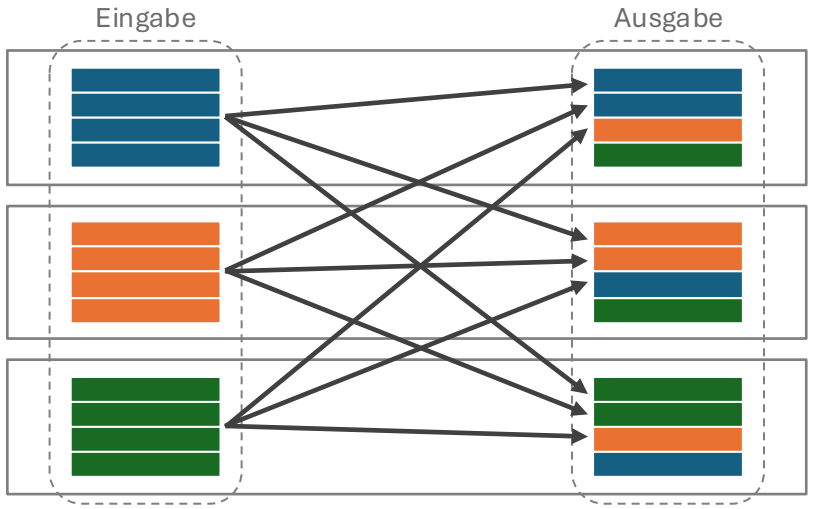


Abb. 3.2: Wide, Partitionen werden neu verteilt (Shuffle)

Merke: Wide Transformations lösen einen **Shuffle** aus und beginnen eine neue Stage, daher sind sie deutlich teurer.